

Sadržaj

1. Uvod	2
2. Konstrukcija distribucijskih vektora	4
3. Kosinusna sličnost	6
4. Programska implementacija	8
4.1. Simuliranje metagenomskog uzorka	9
4.2. Algoritam klasifikacije očitavanja	11
5. Analiza rezultata	14
5.1. Detekcija neočekivanih bakterija i uloga praga threshold	14
5.2. Matrica sličnosti	18
5.3. Klasifikacija stvarnih očitavanja	19
5.4. Klasifikacija očitavanja bez pogreške	21
5.5. Predstavljanje referentnih genoma s više distribucijskih vektora	23
6. Zaključak	27
Literatura	28
Sažetak	29
Abstract	30

1. Uvod

Metagenomski uzorak karakterizira prisutnost genetskog materijala različitih živih organizama. S obzirom na to da je svaka jedinka u složenom međuođnosu s drugim živim bićima u svome okruženju, praktički je nemoguće direktno iz prirode izvući mikrobiološki uzorak s potpuno izoliranim primjercima neke vrste. Bilo da žive u simbiotskom ili parazitskom odnosu, prisutnost jedinki različitih vrsta ključna je za održavanje složenih interakcija u mikrobiološkim zajednicama.

Metagenomika nastoji unaprijediti zdravlje tla, upravljanje ekosustavom, dijagnozu bolesti i biotehnologiju proučavanjem mikrobnih interakcija i raznolikosti. Njene primjene obuhvaćaju poljoprivredu, znanost o okolišu, medicinu, biologiju mora, upravljanje otpadom i prehrambenu industriju. [1]

Uzorci tla, vode i ljudskog mikrobioma neki su od tipičnih uzoraka koji mogu naći u središtu pozornosti metagenomskih analiza. Tako primjerice utvrđivanje prisutnosti neke bakterije u krvi može označavati pojavu sepse, dok istovremeno prisutnost različitih bakterija unutar probavnog sustava ukazuje na kvalitetu mikrobiotskog sastava probavnog trakta.


Metode metagenomske analize prisutne su u nizu bioinformatičkih postupaka, od jednostavnog izoliranja očitavanja pojedine vrste u svrhu daljnjeg istraživanja, do identifikiranja sekvenci bakterijskih genoma odgovornih za rezistentnost prema antibioticima u procesima horizontalnog širenja gena.

U ovome radu provedena je analiza određivanja sastava simuliranog metagenomskog uzorka, tj. zastupljenosti pojedinih mikroorganizama u njemu. Uređaji za sekvenciranje koriste metodu "shotgun" sekvenciranja prema kojoj se višestruko umnožena DNK sekvenca nasumično razbija na manje fragmente. Takvi fragmenti se zatim očitavaju i

standardno zapisuju u FASTA ili FASTQ datoteke kao znakovni nizovi nukleotida A, T, C i G. Duljina očitavanja i udio greške nastao u cijelom procesu ovise o odabranoj tehnologiji sekvenciranja, a za potrebe ovog rada korištena su PacBio očitavanja bakterija čija je prosječna duljina iznosila nekoliko tisuća nukleotidnih baza. Obradom metagenomskog uzorka uređajem za sekvenciranje nastaje veliki skup očitavanja koja potječu od različitih bakterija sadržanih u dotičnom uzorku. Taj skup pomiješanih očitavanja predstavlja glavni predmet promatranja ovog rada. Osnovni je zadatak klasificirati svako takvo očitavanje prema referentnom genomu bakterije s kojega je očitani fragment potekao i tako utvrditi prisutnost i zastupljenost dotičnog mikroorganizma u uzorku. Referentni genomi sadrže kompletnu genomsku informaciju nekog organizma. Dobiveni su sastavljanjem fragmenata te su unaprijed poznati i javno dostupni. Kao i očitavanja, standardno se prikazuju u FASTA ili FASTQ datotekama, a tipična duljina sekvence referentnog genoma mikroorganizama korištenih u ovome radu je nekoliko milijuna nukleotidnih baza. Referentni genomi onih organizama za koje se pretpostavlja da će se pojaviti u metagenomskom uzorku, dodani su u skup referentnih genoma. U svrhu efikasne provedbe postupka klasifikacije, za svako očitavanje iz metagenomskog uzorka i za svaki referentni genom iz skupa referentnih genoma izračunat je pripadni vektor distribucije k-mera. K-mer je podniz genomske sekvence duljine k . Usporedbom sličnosti distribucijskog vektora svakog očitavanja iz uzorka s distribucijskim vektorom svakog referentnog genoma utvrđena je pripadnost pojedinog očitavanja mikroorganizmu s kojega potječe. Kao mjera sličnosti između spomenutih vektora korištena je kosinusna sličnost. S obzirom na to da je klasifikacija proces dodjeljivanja oznaka nepoznatim očitanjima, pojedino očitavanje dobit će oznaku onog referentnog genoma iz skupa referentnih genoma s kojim je ostvarilo najveću kosinusnu sličnost. Uspješnost čitavog postupka opisana je standardnim metrikama za procjenu pouzdanosti modela klasifikacije.

2. Konstrukcija distribucijskih vektora

Supstitucija dugačkih genomskih sekvenci sastavljenih od znakova A, T, C i G numeričkim vektorima fiksne duljine predstavlja temeljni koncept čija će efikasnost i pouzdanost biti detaljno razrađena u ovome radu. Klasična reprezentacija genomskih sekvenci preko znakovnih nizova sadrži izvjesne nedostatke glede efikasne manipulacije podacima tijekom provedbe bilo kakvog oblika analize. Neki od očitih problema svakako uključuju veliko memorijsko zauzeće uslijed velike redundantnosti među podacima te izraženu nekonzistentost među duljinama pojedinih sekvenci. Ideja kojom se nastoje riješiti ovi problemima je reprezentacija znakovnih nizova numeričkim vektorima čije komponente predstavljaju relativnu frekvenciju pojavljivanja određenog k-mera u dotičnom nizu. Način konstrukcije spomenutih vektora predstavljen je na slici 2.1.




Slika 2.1. Konstrukcija distribucijskih vektora preko relativne frekvencije pojavljivanja k-mera

Postupak konstrukcije spomenutih distribucijskih vektora počinje definiranjem posmačnog prozora duljine k koji će se znak po znak pomicati duž čitave genomske sekvence predstavljene tekstualnim znakovima. Veličina prozora k odgovara duljini k -mera, tj. podniza duljine k , na temelju kojeg se želi definirati dotični distribucijski vektor. U primjeru prikazanom na slici 2.1. odabrana je veličina parametra $k=3$. U sljedećem koraku inicijalizira se vektor od 4^k komponenti za svaki mogući 3-mer koji je moguće konstruirati od znakova A, T, C i G. U koraku (1) prolaskom posmačnog prozora duž čitave sekvence bilježi se broj pojavljivanja svakog 3-mera očitano iz posmačnog prozora. Primjerice, podniz "AAA" u zadanoj sekvenci pojavljuje se jednom, podniz "AAC" dvaput, podniz AAG nijednom itd. U koraku (2) brojnost pojavljivanja svakog 3-mera dijeli se s ukupnim brojem 3-mera koji su očitani iz zadane sekvence. S obzirom na to da je zadana sekvenca duljine 9, iz nje je moguće očitati 7 podnizova duljine 3. Taj broj ujedno odgovara i broju pomaka posmačnog prozora definiranog na početku postupka.

Osnovna svrha opisanog postupka je smanjivanje redundantnosti prisutne u znakovnoj reprezentaciji genomske sekvence u FASTA i FASTQ formatu. Bez obzira kolika je duljina zadane sekvence, kao rezultat ovakvog postupka dobije se numerički vektor fiksne duljine koji će predstavljati pogodniju strukturu za daljnje obrade i analize. Bitno je naglasiti kako je duljina tog vektora eksponencijalno ovisna o iznosu parametra k , stoga će mijenjanje tog parametra imati velik utjecaj na vremensku složenost obrade dotičnih vektora kao i na količinu memorijskog prostora koju pojedini vektor zauzima. Također, postupak konstrukcije distribucijskih vektora nije provediv nad očitanjima čija je duljina manja od definiranog iznosa parametra k , stoga je takva očitavanja potrebno zanemariti.

3. Kosinusna sličnost

U postupku klasifikacije očitavanja metagenomskog uzorka na referentne genome kao mjera sličnosti između distribucijskih vektora odabrana je kosinusna sličnost. Spomenuta mjera ima veliku primjenu i izvan područja bioinformatike, naročito u analizi i detektiranju sličnosti između tekstualnih sadržaja. Geometrijska interpretacija kosinusne sličnosti definirana je kao kosinus kuta θ između dva distribucijska vektora i prikazana je na slici 3.1.



Slika 3.1. Geometrijska interpretacija kosinusne sličnosti

Neka su **A** i **B** dva vektora za usporedbu. Koristeći iznos kosinusa kuta između vektora kao funkciju sličnosti, imamo:


$$\text{sim}(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} \quad (3.1)$$

gdje je $\|\mathbf{A}\|$ euklidska norma vektora $\mathbf{A} = (a_1, a_2, \dots, a_p)$, definirana kao $\sqrt{a_1^2 + a_2^2 + \dots + a_p^2}$.

Konceptualno, to je duljina vektora. Slično, $\|\mathbf{B}\|$ je euklidska norma vektora $\mathbf{B}$. Brojnik formule (3.1) predstavlja skalarni umnožak vektora $\mathbf{A}$ i $\mathbf{B}$. Kosinusna sličnost od 0 znači da su dva vektora pod kutom od 90 stupnjeva jedan prema drugome (ortogonalni) i nemaju podudarnost. Što je kosinusna sličnost bliža 1, to je manji kut i veća podudarnost između vektora. [2]

4. Programska implementacija

Programska implementacija alata korištenog za izvođenje analiza obrađenih u ovome radu dostupna je na poveznici https://github.com/Domagoj2002/Analiza_metagenomskog_uzorka_na_temelju_distribucije_k-mera-23-24. Strukturni dijagram navedenog alata prikazan je na slici 4.1.



Slika 4.1. Struktura programske implementacije

Iz ulaznih FASTA i FASTQ datoteka, s pomoću AWK skripte, izvučena su očitavanja i spojena u simulirani metagenomski uzorak predstavljen datotekom metagenomic_sample.fasta. Osim očitavanja dobivenih uređajem za sekvenciranje, pojedine FASTA i FASTQ datoteke opisuju referentne genome na koje je potrebno klasificirati pripadna očitavanja. Datoteke s referentnim genomom mogu sadržavati i sekvencu plazmida koja je zanemarena u provedenim analizama. Parsiranje navedenih datoteka obavlja programski modul bioparser.cpp, koji je integriran u cjelokupnu implementaciju uz pomoć Gita i CMake-a. Spomenuti modul dostupan je na poveznici: <https://github.com/rvaser/bioparser>.

Središnji dio implementacije predstavlja komponenta main.cpp zadužena za manipulaciju podacima i generiranje CSV datoteka koje će potom biti obrađene R skriptama. U konačnici, rezultati su vizualizirani korisniku preko PDF izvještaja. Datoteka CONFIGURATION.txt sadrži osnovne parametre potrebne za obradu i ujedno predstavlja jednostavno sučelje prema korisniku.

4.1. Simuliranje metagenomskog uzorka

Za potrebe izvođenja analiza i procjene pouzdanosti implementiranog modela, nužno je simulirati metagenomski uzorak nad čijim će očitanjima biti proveden cjelokupni postupak klasifikacije na referentne genome. U tu svrhu korištena su stvarna PacBio očitavanja bakterijskih organizama dobivena uređajima za sekvenciranje treće generacije. FASTA i FASTQ datoteke s dotičnim očitanjima i pripadnim referentnim genomima preuzete su iz javno dostupne baze podataka RefSeq i arhiva podataka Zavoda za elektroničke sustave i obradu informacija Fakulteta elektrotehnike i računarstva u Zagrebu.

Za izvlačenje i agregiranje očitavanja iz ulaznih datoteka u metagenomski uzorak korišten je skriptni jezik AWK standardno dostupan na operacijskim sustavima porodice Unix i Linux. Navedeni skriptni jezik specijaliziran je za rad nad tekstualnim podacima i omogućuje izvedbu složenih manipulacija na visokoj razini. Izgled generirane FASTA datoteke metagenomskog uzorka prikazan je na slici 4.2.

```
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/2754_4950
ATATGACCATAAATTACCGTCCGAGCTACATAGAATAAATCAGGCCCTGCTCTTTATATTTAATTGGCGGAGTCAAACCTGTTCTTACCAGTTGAAGTACATCTAGTATCGTTGAATTAAGGGAATTACAT
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/4995_8885
TTACTTCATAAATTGCGTCTATTATTAACCGTTAAAAACAACCTTTGTCATATCATGCGAAAGAAGATTAGTGAAGGTGATTTAACAGAATCAAATTAACAGTTCAATTCACAGATGAAATTAACAGCTAGGAG
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/8929_12873
GCTACTACGGAATTAGTGCAGCTGAAATGGGACGTGCTGCTTACTAGGCAACGCCGTTCAACAATTATTAGTCCTCTTGTGCTCCACTTATTTATTGGTCGGAATAAGGAAAGTGGATTTTCGGTGAACAA
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/12917_16833
TTACTTTTATAAGTGCGTCTATTATTAACCGCTTAAAAACAACCTTTGTCATATCATGCGAAAGAAGATTAGTGAAGGTGATTTAACCGAATCAATTACAGTTCAATCTAAGAGATGAAATGGATCAGCTAGGAGA
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/16876_20804
TCTACTTTACGGAATTAGTGCAGCTGAAATCGGACGTAGCTTTTCTTACTTGGGCAAAACCGTTTCAAGTATCTAGTCCTCTGCTGCCACTTCTTTATTGGTCGGAATGGCAAAAGTTGACATTTCCG
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/9/20854_23494
TTATTTTATAAATTGCGTCTATTATTAACCGTTAAAAACAACCTTTGTCATATCATGCGAAAGAAGATTAGTGAAGGTGATTTATTACAGAATCATTACAGTTCAATCTAAAAAGAGTGAATGGGACAGCTGAG
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/10/0_7123
AGAGAGATGTATGAGAATAGAGCAGTTTCAATATATTAAGAGAAAAATGAGGCGGTTGCTTTTATATGAGAACACTCACTAGTGGTTAAGGGCAAGCGCATGATGATGAAAGCAATCCGCGGAAATTTTCG
>m151217_030803_00127_c100958662550000001823217206251655_s1_p0/10/7166_9056
TTAAGTGACCAACAAATGAGATCAGTTTATACCAAGTACTGTATCGCCTTAAATCGTGAAAGTATACCTGCCATGTTGCTGTGACACAGAGTGTGGTTTGAACATTTACGTGCTCTCGGCGCCGA
```

Slika 4.2. Izgled datoteke metagenomic_sample.fasta


Svaki zapis započinje znakom ">", a nakon njega slijede metapodaci o dotičnoj sekvenci očitavanja dobivenog uređajem za sekvenciranje. U sljedećem retku zapisana je sekvencija kao niz znakova A,T,C i G koji predstavljaju nukleotidne baze. Moguće je da se u ulaznim FASTA/FASTQ datotekama pronađu i drugi znakovi koji između ostalog mogu

označavati nepoznatu nukleotidnu bazu. Navedeni slučaj očituje se kada FASTA datoteke opisuju cjelokupni genom organizma, a pojedini dijelovi tog genoma još nisu u potpunosti određeni. FASTQ format sadrži sve informacije kao i FASTA format, samo što je svaki zapis dodatno opisan retkom koji sadržava ocjenu kvalitete odgovarajuće nukleotidne baze u sekvenci. Navedene dodatne informacije nisu bile nužne za provedbu željenih analiza stoga je FASTQ format datoteka trivijalno pretvoren u FASTA format brisanjem nadodanih redaka. Za taj postupak također je korištena AWK skripta, a odsječak koda koji izvršava tu funkcionalnost prikazan je na slici 4.3.

```
211 // Funkcija za pretvaranje fastq datoteke u fasta pomoću awk
212 void convert_fastq_to_fasta(const string& fastq_file, const string& data_directory) {
213     string fasta_file = regex_replace(fastq_file, regex("\\.fastq$"), ".fasta");
214     string command = "awk 'if(NR%4==1) {printf(>%s\\n\\n", substr($0, 2));} else if(NR%4==2) print;}' "...
215     system(command.c_str());
216 }
```

Slika 4.3. Primjer korištenja awk naredbe

Spomenuti metagenomski uzorak sastoji se od desetak tisuća očitavanja poteklih od deset različitih vrsta bakterijskih organizama. Zastupljenosti očitavanja svake od bakterija u generiranom metagenomskom uzorku prikazane su na slici 4.4.



Slika 4.4. Zastupljenost pojedinih bakterijskih očitavanja unutar metagenomskog uzorka

Tablica 4.1. Karakteristike očitavanja sadržanih u metagenomskom uzorku

	prosječna duljina	standardna devijacija	broj očitavanja
b. cereus	3197.32	2374.66	1000
e. coli	3562.20	2329.97	1170
h. influenzae	2408.72	1672.58	970
h. pylori	4244.31	4141.23	1057
l. gasseri	3372.48	3032.21	768
p. agglomerans	3681.23	3575.97	978
p. aeruginosa	2527.66	1811.30	927
s. enterica	4257.48	3923.76	1190
s. pneumoniae	3575.85	2848.66	1240
s. urinalis	3777.84	3546.22	707

Očitavanja pojedine bakterije nalaze se uvijek na susjednim mjestima unutar generirane FASTA datoteke metagenomskog uzorka. Prvih 1000 očitavanja u uzorku pripadaju bakteriji *b. cereus*, sljedećih 1170 očitavanja bakteriji *e.coli* itd. Ovakav pristup generiranju reprezentativnog uzorka ne utječe na tijek analize, ali uvelike poboljšava preglednost nekih od vizualizacija korištenih u nastavku.

4.2. Algoritam klasifikacije očitavanja

Osnovni zadatak u analizi metagenomskog uzorka je klasifikacija svakog očitavanja prema pripadnom referentnom genomu s kojeg potječe. Nakon konstrukcije distribucijskih vektora iz očitavanja i referentnih genoma, potrebno je svako očitavanje usporediti na temelju kosinusne sličnosti sa svakim dostupnim referentnim genomom. Pojedino očitavanje poprima oznaku onog distribucijskog vektora iz skupa referentnih genoma s kojim ostvari najveću kosinusnu sličnost. Spomenuti postupak implementiran je u programskom jeziku R, a odsječak tog koda prikazan je slici 4.5.

```

278 # Funkcija za čitanje CSV datoteke u dijelovima po 500 stupaca
279 read_csv_in_chunks <- function(file_path, chunk_size = 500) {
280   num_cols <- ncol(fread(file_path, nrows = 1))
281   chunks <- split(1:num_cols, ceiling(seq_along(1:num_cols) / chunk_size))
282
283   predicted_labels <- vector()
284
285   for (chunk in chunks) {
286     fragments_vectors <- fread(file_path, select = chunk)
287     fragments_matrix <- as.matrix(fragments_vectors)
288
289     for (i in 1:ncol(fragments_matrix)) {
290       similarities <- apply(reference_matrix, 2, cosine_similarity, b = fragments_matrix[, i])
291       max_similarity <- max(similarities)
292
293       if (max_similarity >= 0.00) { # provjera praga threshold
294         predicted_labels <- c(predicted_labels, bacteria_names[which.max(similarities)])
295       } else {
296         predicted_labels <- c(predicted_labels, NA)
297       }
298     }
299
300     # Oslobađanje memorije zauzete fragment matrix jer više nije potrebna
301     rm(fragments_matrix, fragments_vectors)
302     gc()
303   }
304
305   return(predicted_labels)
306 }

```

Slika 4.5. Algoritam klasifikacije očitavanja

Za veće iznose parametra k , CSV datoteka s distribucijskim vektorima simuliranog metagenomskog uzorka zauzima veliku količinu memorije, stoga je nužno uzastopno učitavati manje dijelove te datoteke i postupak provoditi nad manjim brojem vektora.

U liniji 293 sa slike 4.5. implementirana je dodatna provjera zadovoljavanja praga `threshold` koju svako očitavanje mora proći kako bi postalo klasificirano. U suprotnome, dotično očitavanje svrstava se u grupu neklasificiranih očitavanja. Značenje i uloga navedenog praga sličnosti bit će detaljno razrađena u poglavlju 5.1.


Matrica `reference_matrix` sadrži distribucijske vektore referentnih genoma iz učitane CSV datoteke. Prvi redak CSV datoteka opisuje imena stupaca i korišten je za prijenos stvarnih oznaka. Na kraju postupka klasifikacije svakome očitavanju bit će dodijeljena predviđena oznaka. Pouzdanost dotičnog modela klasifikacije svodi se na usporedbu u kojoj mjeri stvarne oznake odgovaraju predviđenima. Simulirani metagenomski uzorak opisan u poglavlju 4.1. sadržava očitavanja deset bakterija dok se u `reference_matrix` nalaze vektori osam bakterija. Distribucijski vektori referentnih genoma bakterija l. ga-

sseri i s. urinalis namjerno su izostavljeni kako bi se ilustrirao slučaj kada se postupak klasifikacije vrši s nepotpunim skupom referentnih genoma. Navedeni slučaj odgovara stvarnom scenariju u kojem se analizira metagenomski uzorak čiji sastav nije unaprijed poznat.

5. Analiza rezultata

5.1. Detekcija neočekivanih bakterija i uloga praga threshold

S obzirom na to da se u skupu distribucijskih vektora referentnih genoma ne nalaze svi genomi čija su očitavanja prisutna i u metagenomskom uzorku, postavlja se pitanje je li moguće identificirati očitavanja iz uzorka za koja ne postoji pripadni referentni genom u skupu referentnih genoma. Za pretpostaviti je da će očitavanja koja nemaju svoj pripadni referentni genom ostvariti nižu kosinusnu sličnost u trenutku klasifikacije u odnosu na očitavanja koja ga imaju zbog činjenice da su nužno klasificirana na pogrešan referentni genom. Navedenu pretpostavku moguće je provjeriti crtanjem točkastog grafa koji će za svako očitavanje metagenomskog uzorka prikazati iznos kosinusne sličnosti na temelju koje je izvršena klasifikacija odnosno dodjeljivanje predviđene oznake. Taj iznos ujedno odgovara najvećoj mogućoj kosinusnoj sličnosti koju distribucijski vektor pojedinog očitavanja postigne prilikom sparivanja sa svakim dostupnim referentnim genomom. U tu svrhu u metagenomskom uzorku korištena su očitavanja bez greške dobivena direktno iz referentnih genoma bakterija kako bi se eliminirao utjecaj greške u originalnim očitavanjima. Duljine očitavanja bez greške odgovaraju originalnim očitavanjima. Navedeni grafički prikaz za distribucijske vektore definirane za iznos parametra $k = 6$ prikazan je na slici 5.1.




Slika 5.1. Detekcija neočekivanih bakterija

Crvenom bojom istaknuti su indeksi očitavanja iz metagenomskog uzorka koji nemaju svoj pripadni referentni genom. Zbog načina simuliranja reprezentativnog metagenomskog uzorka u kojem se očitavanja pojedine bakterije nalaze na susjednim indeksima unutar uzorka, lako je uočiti svojstvo grupacije postignutih maksimalnih kosinusnih sličnosti prema rasponu indeksa unutar kojeg se nalaze genomska očitavanja pojedine bakterije. U skladu s navedenim, uvidom u tablicu 4.1. moguće je zaključiti kako se očitavanja bakterije *L. gasseri* nalaze od 4196. do 4965. indeksa unutar simuliranog uzorka. Analogno, raspon indeksa očitavanja bakterije *S. urinalis* proteže se od 9299. pa do zadnjeg indeksa u uzorku. Ključno je uočiti kako očitavanja spomenutih bakterija, čije pojavljivanje nismo očekivali u provedenom eksperimentu, unatoč klasificiranju na pogrešan referentni genom postižu dovoljno dobre vrijednosti maksimalne kosinusne sličnosti da bi se trivijalno mogle identificirati. Postupak je proveden za distribucijske vektore definirane za parametar k iznosa od 3 do 9, ali rezultati su gotovo identični prethodnom primjeru.

S obzirom na to da pokušaj detekcije neočekivanih bakterija nije dao pozitivne rezultate, analiza je nastavljena promatranjem distribucije točno i pogrešno klasificiranih očitavanja nad identičnim uzorkom. U skladu s navedenim grafički prikaz sa slike 5.1. je

modificiran tako da zelene točkice prikazuju točno klasificirana očitavanja, a crveni križići netočno dodijeljenu predviđenu vrijednost. Rezultati su prikazani na slici 5.2.



Slika 5.2. Distribucija točno i pogrešno klasificiranih očitavanja

Neposredno ispod područja u kojem se nalazi najveća koncentracija ostvarenih vrijednosti maksimalne kosinusne sličnosti povučen je horizontalni pravac koji će u nastavku rada biti referiran pod pojmom prag sličnosti `threshold` i u dotičnom primjeru odgovara jednadžbi pravca $y = 0.42$. U nastavku su pobrojena točno i netočno klasificirana očitavanja ispod i iznad povučenog pravca, a rezultatni ispis R skripte koja izvršava navedenu funkcionalnost prikazan je na slici 5.3.


```
Postotak netočno klasificiranih očitavanja iznad praga threshold = 0.42: 10.35125 %
Postotak netočno klasificiranih očitavanja ispod praga threshold = 0.42: 31.36842 %
```

Slika 5.3. Usporedba područja iznad i ispod praga `threshold`

Jasno je vidljivo kako se u području ispod praga sličnosti nalazi uvjerljivo više pogrešno klasificiranih očitavanja u odnosu na područje iznad. Očitavanja neočekivanih bakterija *L. gasseri* i *S. urinalis* su pri izračunu navedenih postotaka zanemarena jer je očito da će nužno biti pogrešno klasificirana.

Dodatno, moguće je fokusirati se na jednu klasu bakterija, npr. *B. cereus*, čija se očitavanja nalaze na samom početku metagenomskog uzorka, te promatrati raspored stvarnih

pozitiva i negativa te lažnih pozitiva i negativa. Navedeno je prikazano na slici 5.4.



Slika 5.4. Usporedba područja iznad i ispod praga threshold (2)

Također je uz zanemarivanje neočekivanih bakterija moguće zamijetiti veću prisutnost lažnih negativa i lažnih pozitiva među očitanjima koja su postigla maksimalnu kosinusnu sličnost manju od definiranog praga threshold. Navedeno ukazuje da će definiranje praga sličnosti imati utjecaj na mjere pouzdanosti implementiranog modela klasifikacije. Ako se sva očitavanja koja ne zadovolje prag sličnosti threshold svrstaju u skup neklasificiranih očitavanja moguće je optimirati performanse modela. Skup neklasificiranih očitavanja bi u općenitom slučaju trebao biti znatno manji od skupa očitavanja koji se našao iznad praga te ga je moguće obraditi i nekim egzaktnijim metodama. Performanse korištenog modela za originalna očitavanja s greškom i parametre $k = 6$ i $\text{threshold} = 0.42$ prikazane su u rezultatnom ispisu R skripte na slici 5.5.;

```

Mikroprosječne vrijednosti:
0.7948977
-----
Broj neklasificiranih očitavanja (a/b): 690/10007

Makroprosječne vrijednosti:

Preciznost:0.7959517
Odziv:0.8074889
F1-rezultat:0.7954107

```

Slika 5.5. Performanse modela klasifikacije ($k = 6$, threshold = 0.42)

Podizanjem praga sličnosti model postaje skloniji uvrštavanju očitavanja u skup neklasificiranih očitavanja. Spuštanjem praga do izražaja dolaze lažni pozitivni i negativni što nepovoljno utječe na performanse modela.


Određivanje praga sličnosti na analogan način moguće je provesti i za modele koji koriste distribucijske vektore s drukčijim iznosom parametra duljine k -mera k , no ključno je postavljati taj prag zasebno za svaki model jer prosječna maksimalna kosinusna sličnosti koju zajedno ostvaruju sva očitavanja metagenomskog uzorka u trenutku klasifikacije pada s porastom parametra k . Opisani slučaj prezentiran je i tablicom 5.1.;

Tablica 5.1. Zbirne karakteristike očitavanja metagenomskog uzorka

duljina k-mera	prosječna kosinusna sličnost	standardna devijacija
3	0,9635011	0,0406249
4	0,9216328	0,0701713
5	0,8338573	0,1066321
6	0,6792655	0,1386596
7	0,4780890	0,1408899
8	0,2955324	0,1117662

5.2. Matrica sličnosti

Kosinusnu sličnost moguće je računati i između distribucijskih vektora isključivo referentnih genoma. Rezultati dobiveni takvom analizom mogu pomoći u objašnjavanju pogrešaka prikazanih u tablici zabune jer je u slučaju pogrešne klasifikacije očitavanja izgledno da se ono klasificiralo na genom koji najbližiji onome genome kojem dotično očitavanje uistinu i pripada. Opisani scenarij ilustriran je matricom sličnosti na slici 5.6.;




Slika 5.6. Matrica sličnosti referentnih genoma ($k = 9$)

Riječ je o simetričnoj matrici s maksimalnim vrijednostima na glavnoj dijagonali jer je svaki genom maksimalno sličan samom sebi. U prikazanoj matrici korištena je transformacija skale eksponencijalnom funkcijom kako bi se jače naglasila razlika među referentnim genomima.

5.3. Klasifikacija stvarnih očitavanja

U konačnici je proveden cjelokupni postupak klasifikacije stvarnih očitavanja metagenomskog uzorka na referentne genome. Rezultate spomenutog postupka moguće je prikazati matricom zabune koja prikazuje uspješnost dodjeljivanja ispravnih predviđenih oznaka u odnosu na stvarne oznake. Postupak je ponovo proveden za model s distribucijskim vektorima definiranim za parametar $k = 6$, a neočekivane bakterije *l. gasseri* i *s. urinalis* nisu uključene u prikaz rezultata jer zbog neprisutnosti njihovih referentnih genoma preostale bakterije ne mogu poprimiti njihove predviđene oznake. Matrica zabune prikazana je na slici 5.7.



Slika 5.7. Matrica zabune za stvarna očitavanja ($k = 6$, threshold = 0)

Veća pouzdanost modela povlači više ispravno dodijeljenih predviđenih oznaka, odnosno veću grupaciju očitavanja na glavnoj dijagonali matrice zabune. Najlošiji udjeli ispravno dodijeljenih predviđenih oznaka uočljivi su kod bakterija p. agglomerans, s. enterica i e. coli. Uvidom u matricu sličnosti na slici 5.6. uočljiva je relativno velika međusobna sličnost genoma bakterija e. coli i s. enterica, dok je p. agglomerans slična s obje prethodne bakterije. Navedeno potvrđuju i performanse modela gledano po pojedinoj bakteriji prikazane u rezultatnom ispisu R skripte na slici 5.8.

Bakterija <chr>	Preciznost <dbl>	Odziv <dbl>	F1_rezultat <dbl>
b.cereus	0.8930000	0.6944012	0.7812773
e.coli	0.6401709	0.5842434	0.6109299
h.influenzae	0.8731959	0.8028436	0.8365432
h.pylori	0.9035005	0.8967136	0.9000943
p.agglomerans	0.5092025	0.8110749	0.6256281
p.aeruginosa	0.8522114	0.9427208	0.8951841
s.enterica	0.6815126	0.7151675	0.6979346
s.pneumoniae	0.8379032	0.8259141	0.8318655

Slika 5.8. Performanse po pojedinoj bakteriji za stvarna očitavanja ($k = 6$, threshold = 0)

Postupak je proveden i za modele s distribucijskim vektorima definiranim za drukčije

vrijednosti parametra duljine k-mera. Prag sličnosti `threshold` je za sve modele postavljen na nulu jer njegovo određivanje za svaki model zasebno može uvesti pristranost što nije poželjno u postupku usporedbe različitih modela. Rezultati su prikazani na tablici 5.2.


Tablica 5.2. Usporedba modela s različitim parametrima `k` za stvarna očitavanja (`threshold = 0`)

duljina k-mera	makroprosječne vrijednosti			mikro-prosjek
	preciznost	odziv	f1-rezultat	prosjek
3	0.717261	0.723094	0.716901	0.713549
4	0.741525	0.748385	0.740686	0.738631
5	0.761405	0.769441	0.760175	0.758673
6	0.773837	0.784135	0.772432	0.771449
7	0.783239	0.796277	0.782478	0.781411
8	0.789974	0.806876	0.789937	0.788444

Porastom parametra `k` primjetno je postupno poboljšanje performansi modela, no ono je relativno sporo u odnosu na povećanje memorijske i vremenske složenosti čitavog postupka. Usporedbom performansi modela s parametrom `k = 6` s rezultatima prethodno prikazanim na slici 5.5. može se ilustrirati utjecaj praga `threshold` na optimizaciju performansi modela.

5.4. Klasifikacija očitavanja bez pogreške

Originalna očitavanja dobivena uređajem za sekvenciranje karakterizira postojanje pogrešaka u očitanim genomskim sekvencama. Kako bi se utvrdio utjecaj pogrešaka na postupak klasifikacije očitavanja, uzimanjem podnizova s referentnih genoma simulirana su očitavanja bez greške. Duljine očitavanja odgovaraju originalnim očitanjima, a pozicije na referentnim genomima s kojih su uzimani podnizovi, izvučeni su iz uniformne razdiobe kako bi se izbjeglo preferiranje dijelova sekvence koji su više ili manje skloni greškama pri očitavanju. Matrica zabune za model s parametrima `k = 6` i `threshold = 0` prikazana je na slici 5.9.



Slika 5.9. Matrica zabune za očitavanja bez greške ($k = 6$, threshold = 0)

Moguće je uočiti kako su najbolje rezultate klasifikacijskog postupka postigla očitavanja bakterije *h. pylori* jer je 98.20% očitavanja te bakterije dobilo ispravnu predviđenu oznaku. Najlošiji rezultat postigla su očitavanja bakterije *s. enterica* kod koje je uočljivo kako je čak 15.21% očitavanja neispravno klasificirano na genom bakterije *e. coli*. Uvidom u matricu sličnosti sa slike 5.6. može se uočiti velika sličnost genoma tih dviju bakterija što objašnjava pojavu zabune. Kod bakterije *p. agglomerans* je uočljivo najznačajnije povećanje u udjelu ispravno klasificiranih očitavanja u odnosu na slučaj s originalnim očitanjima. Toliko izražen utjecaj grešaka u očitanjima te bakterije u procesu klasifikacije dodatno je naglašen činjenicom da dotična bakterija ima relativno veliku genomsku sličnost s bakterijama *e. coli* i *s. enterica* što je također vidljivo u matrici sličnosti na slici 5.6. Sve navedeno potvrđuju i performanse modela po pojedinoj bakteriji vidljive u ispisu R skripte prikazanom na slici 5.10.

Bakterija <chr>	Preciznost <dbl>	Odziv <dbl>	F1_rezultat <dbl>
b.cereus	0.9490000	0.8104184	0.8742515
e.coli	0.8085470	0.7333333	0.7691057
h.influenzae	0.9278351	0.9211873	0.9244992
h.pylori	0.9820246	0.9933014	0.9876308
p.agglomerans	0.8486708	0.8495394	0.8491049
p.aeruginosa	0.9751888	0.9847495	0.9799458
s.enterica	0.7512605	0.9048583	0.8209366
s.pneumoniae	0.8774194	0.9331046	0.9044057

Slika 5.10. Performanse po pojedinoj bakteriji za očitavanja bez greške (k = 6, threshold = 0)

Postupak je proveden i za modele s distribucijskim vektorima definiranim za drukčije vrijednosti parametra duljine k-mera. Prag sličnosti threshold ponovo je za sve modele postavljen na nulu. Rezultati su prikazani na tablici 5.3.


Tablica 5.3. Usporedba modela s različitim parametrima k za očitavanja bez greške (threshold=0)

duljina k-mera	makroprosječne vrijednosti			mikro-prosjek
	preciznost	odziv	f1-rezultat	prosjek
3	0.820365	0.817750	0.815816	0.811650
4	0.856299	0.855353	0.853887	0.849391
5	0.873751	0.874809	0.871826	0.867792
6	0.889993	0.891312	0.888735	0.884787
7	0.895328	0.898392	0.894387	0.890764
8	0.915926	0.918546	0.914845	0.912213

Trend poboljšanja performansi i kod očitavanja bez pogreške je i dalje relativno spor.


5.5. Predstavljanje referentnih genoma s više distribucijskih vektora

S ciljem detaljnije reprezentacije referentnih genoma moguće je dotične genome razlomiti na manje nizove te za svaki taj niz konstruirati pripadni distribucijski vektor. Pritom je važno uzeti u obzir činjenicu kako je većina bakterijskih genoma cirkularne građe što znači da su početak i kraj sekvence spojeni. Također bitno je ostaviti preklapanje između nizova kako bi spriječio slučaj da se dio očitavanja nađe u jednom, a dio u drugom distribucijskom vektoru istog referentnog genoma. Opisani postupak ilustriran je slici 5.11.



Slika 5.11. Opis cirkularnog genoma distribucijskim vektorima

Bez ulaženja u dublje biološke osnove, za potrebe ovog rada pretpostavljeno je da su svi genomi bakterija iz metagenomskog uzorka cirkularne građe. Glede određivanja parametara overlap i length intuitivno je jasno da se u slučaju premalog iznosa parametra length povećava vjerojatnost da se s različitih genoma odrežu međusobno slični dijelovi koji mogu uzrokovati zabunu pri klasifikaciji. Minimalan iznos parametra overlap teoretski bi trebao odgovarati maksimalnoj duljini očitavanja prisutnog u metagenomskom uzorku. Obrnuto, u slučaju prevelikog iznosa parametra length situacija se neće previše razlikovati od korištenja jednog distribucijskog vektora po referentnom genomu. Matrica zabune za model sa stvarnim očitanjima i parametrima $k = 6$, $\text{threshold} = 0$, $\text{length} = 500\,000$ i $\text{overlap} = 250\,000$ prikazana je na slici 5.12.



Slika 5.12. Matrica zabune za genome predstavljene s više vektora ($k = 6$, threshold = 0)

Uočljivo je kako je kod nekih bakterija udio ispravno klasificiranih očitavanja veći, a kod nekih manji. Navedeno potvrđuju i performanse modela po pojedinoj bakteriji prikazanih na slici 5.13.

Bakterija <chr>	Preciznost <dbl>	Odziv <dbl>	F1_rezultat <dbl>
b.cereus	0.9350000	0.6493056	0.7663934
e.coli	0.5905983	0.6612440	0.6239278
h.influenzae	0.8298969	0.8106747	0.8201732
h.pylori	0.8855251	0.9078565	0.8965517
p.agglomerans	0.5132924	0.8494078	0.6398980
p.aeruginosa	0.8629989	0.9489917	0.9039548
s.enterica	0.7773109	0.6588319	0.7131843
s.pneumoniae	0.8282258	0.8666667	0.8470103

Slika 5.13. Performanse po pojedinoj bakteriji za genome predstavljene s više vektora ($k = 6$, threshold = 0)

Zbirne metrike pouzdanosti modela, koji se razlikuju za parametar k , prikazane su u tablici 5.4.

Tablica 5.4. Usporedba modela s različitim parametrima k za genome predstavljene s više vektora (threshold=0)

duljina k-mera	makroprosječne vrijednosti			mikro-prosjek
	preciznost	odziv	f1-rezultat	prosjek
3	0.720405	0.736468	0.719151	0.718823
4	0.746068	0.763234	0.744782	0.744608
5	0.766221	0.781923	0.764590	0.764416
6	0.777856	0.794122	0.776384	0.776020
7	0.783126	0.800985	0.782145	0.781411
8	0.795291	0.813303	0.795009	0.793601

Uspoređujući navedene zbirne performanse sa slučajem u kojem je pojedini referentni genom predstavljen jednim distribucijskim vektorom (prikazano na tablici 5.2.) uočljiva je zanemariva promjena u performansama modela. Dodavanje vektora u skup referentnih genoma ima bitno veći utjecaj na vremensko izvršavanje od dodavanja vektora u skup očitavanja jer je u općenitom slučaju skup očitavanja metagenomskog uzorka uvjerljivo veći od skupa referentnih genoma te je potrebno odraditi više operacija usporedbe.

6. Zaključak

Osnovni korak u analizi metagenomskog uzorka podrazumijeva određivanje prisutnosti i mjerenje zastupljenosti živih organizama koji se u njemu nalaze. Predstavljanje referentnih genoma i genomskih očitavanja distribucijskim vektorima omogućuje njihovu efikasnu usporedbu na temelju nekih od mjera sličnosti. Određivanje minimalnog praga sličnosti, koje svako očitavanje mora zadovoljiti da bi bilo klasificirano, može poboljšati metrike pouzdanosti modela. Navedeni prag potrebno je određivati za svaki model (definiran iznosom k) zasebno te nije u stanju detektirati očitavanja neočekivanog genetskog materijala. U skladu s navedenim nužno je pobrinuti se da se u skupu referentnih genoma pojavljuju pripadni genomi svih očitavanja iz metagenomskog uzorka ili odraditi predobradu koja je u stanju detektirati očitavanja neočekivanih organizama. Povećanje parametra k , kojim je definiran postupak konstrukcije distribucijskih vektora za svaki model, pozitivno utječe na metrike pouzdanosti, no kao posljedicu ostavlja veliku memorijsku i vremensku složenost. U svrhu eventualnog ublažavanja navedenih efekata bit će nužno poslužiti se većim računalnim resursima i primjeni metoda paralelizacije i sinkronizacije. Pogreške prisutne u očitanjima negativno djeluju na postupak klasifikacije. Predstavljanje referentnih genoma s više distribucijskih vektora nema izražen utjecaj na pouzdanost modela. Činjenica da je dotični genom detaljnije opisan poništi se efektom zabune klasifikacijskog postupka u slučaju kada se pojave slični dijelovi različitih genoma. U tom kontekstu problematično je i određivanje optimalnog iznosa duljine dijelova referentnih genoma za koje je potrebno konstruirati distribucijski vektor jer efikasnost metode direktno ovisi o sastavu metagenomskog uzorka i međusobnoj sličnosti referentnih genoma.

Literatura

- [1] A. K. Wani, F. Rahayu, A. M. Alkahtani, M. A. Alreshidi, K. K. Yadav, Parnidi, L. Fauziah, M. Murianingrum, N. Akhtar, E. Mufidah, Supriyadi, D. M. Rahayu, i R. Singh, “Metagenomic profiling of rhizosphere microbiota: Unraveling the plant-soil dynamics”, *Physiological and Molecular Plant Pathology*, sv. 133, str. 102381, 2024. <https://doi.org/https://doi.org/10.1016/j.pmpp.2024.102381>

- [2] J. Han, M. Kamber, i J. Pei, “2 - getting to know your data”, u *Data Mining (Third Edition)*, third edition izd., ser. The Morgan Kaufmann Series in Data Management Systems, J. Han, M. Kamber, i J. Pei, Ur. Boston: Morgan Kaufmann, 2012., str. 39–82. <https://doi.org/https://doi.org/10.1016/B978-0-12-381479-1.00002-2>

Sažetak

Analiza metagenomskog uzorka na temelju distribucije k-mera

Domagoj Sviličić

Tema ovog rada je analiza metagenomskog uzorka na temelju distribucije k-mera. Metagenomski uzorak je skup genomske sekvenci koji potječu od različitih organizama, a dobivene su uređajem za sekvenciranje genoma. Postupak se temelji na predstavljanju genomske sekvenci preko distribucijskih vektora nad kojima se provodi usporedba s referentnim genomima na temelju kosinusne sličnosti. Razrađuju se i slučajevi efikasnosti klasifikacijskog algoritma kada u metagenomskom uzorku nije unaprijed poznat sastav živih organizama. Analizom odgovarajućih parametara analizira se pouzdanost klasifikacije opisanog modela.

Ključne riječi: metagenomski; bioinformatika; distribucija; vektor; k-mer

Abstract

Metagenomic Sample Analysis Using k-mer Distribution

Domagoj Sviličić

The topic of this study is the analysis of a metagenomic sample based on k-mer distribution. A metagenomic sample is a set of genomic sequences derived from different organisms, obtained using a genome sequencing device. The process is based on representing genomic sequences through distribution vectors, which are then compared with reference genomes based on cosine similarity. Cases of the efficiency of the classification algorithm are also elaborated when the composition of living organisms in the metagenomic sample is not known in advance. By analyzing the corresponding parameters, the reliability of the classification of the described model is assessed.

Keywords: metagenomic; bioinformatics; distribution; vector; k-mer